

Machine Learning for Climate Risk

Prédiction du SWI Uniforme et des sécheresses

Thomas PASQUIER – Elric ROUSSEL

ENSAE MS Actuariat - 2025/2026

Introduction

L'aggravation de la fréquence et de l'intensité des épisodes de sécheresse causée par le dérèglement climatique est un défi majeur auquel sont confrontés les pouvoirs publics et le secteur de l'assurance. Selon une modélisation réalisée par la CCR (Caisse Centrale de Réassurance), le scénario d'une sécheresse centennale à l'échelle de la France pourrait causer des dommages dans plus de 33 000 communes, entraînant des pertes assurées pouvant atteindre 6 milliards d'euros.

Ainsi, pour faire face aux risques majeurs causés par la sécheresse des sols, tels que les pertes agricoles ou le phénomène de retrait-gonflement des argiles (RGA), il est crucial d'avoir une connaissance précise de l'état hydrique des sols. Le **Soil Water Index** (SWI), qui mesure la teneur en eau à deux mètres de profondeur, est l'indicateur de référence pour mesurer le niveau d'humidité des sols. Pour mesurer le risque RGA dans le dispositif CatNat, Météo-France s'appuie sur le **SWI uniforme**. Cet indicateur vise à neutraliser les hétérogénéités géologiques locales en simulant un sol standard sur tout le territoire français.

Ces deux indicateurs dépendent de l'observation directe des sols, souvent difficile à mettre en œuvre. Ainsi, Météo France estime ces indicateurs en utilisant le modèle SIM (Safran-Isba-Modcou), un modèle physique complexe. Ce projet a donc pour objectif de prédire l'état hydrique des sols en modélisant le SWI uniforme à l'aide de méthodes de Machine Learning moins coûteuses. Dans un premier temps, le SWI uniforme sera modélisé à l'aide de variables explicatives et, dans un second temps, ces prédictions seront utilisées pour prédire les événements de sécheresse.

1 Importation et traitement des données

Les données mobilisées dans ce travail proviennent de quatre sources publiques distinctes : les champs météorologiques quotidiens SAFRAN-SIM, l'indice mensuel d'humidité des sols SWI uniforme, la cartographie nationale du retrait-gonflement des argiles (RGA 2020, BRGM) et le référentiel administratif *ADMIN EXPRESS* de l'IGN.

L'exploitation conjointe de ces différentes bases a nécessité un travail conséquent de pré-traitement. En effet, certaines d'entre elles, et en particulier la base SAFRAN, représentent un volume de données très important (environ 30 Go), rendant leur manipulation directe impossible compte tenu des contraintes de mémoire.

Dans un premier temps, les données SAFRAN ont donc été agrégées d'une résolution journalière à une résolution mensuelle afin de réduire significativement leur taille. Cette agrégation a été réalisée en calculant, selon la nature des variables, des statistiques mensuelles telles que la moyenne, le minimum ou le maximum. Ce choix permet par ailleurs d'assurer la cohérence temporelle avec les données de Météo-France, disponibles à une échelle mensuelle, et de faciliter les opérations de jointure entre bases.

Parallèlement, la cartographie du retrait-gonflement des argiles a été récupérée et convertie dans un format compatible avec les autres jeux de données afin de permettre son intégration dans les analyses ultérieures.

2 Visualisation des données et analyse

Avant d’entamer la modélisation du SWI uniforme et la prédiction des événements de sécheresse anormale, nous commençons par une analyse préliminaire des données et une représentation graphique de celles-ci.

Dans un premier temps, une **matrice de corrélation** a été réalisée à partir de **l’ensemble des variables numériques** issues des bases de données à notre disposition. Cette matrice permet d’identifier les relations linéaires entre les variables explicatives et le SWI uniforme :

- Le SWI uniforme présente une corrélation significative avec de nombreuses variables météorologiques, ce qui valide sa pertinence comme indicateur synthétique de l’état hydrique des sols ;
- La corrélation entre le SWI uniforme et le niveau d’argile est faible. Celle-ci s’explique par la nature du SWI uniforme, qui vise à modéliser un sol uniforme sur le territoire français et donc ne dépend pas du niveau d’argile.

Dans un second temps, nous avons tracé des cartes des surfaces argileuses de quatre régions françaises (Bretagne, Grand Est, Provence-Alpes-Côte d’Azur et Nouvelle-Aquitaine) afin d’explicitier les disparités d’exposition au risque RGA au sein du territoire français :




FIGURE 1 – Cartes des surfaces argileuses de quatre régions françaises

L’examen de ces cartes met en évidence l’hétérogénéité du risque RGA sur le territoire français causée par la composition du sol de chaque région. En particulier, l’étendue des surfaces argileuses de niveau 3 en région Nouvelle-Aquitaine en fait une région fortement exposée au risque RGA. Nous avons donc choisi de réaliser plusieurs analyses spécifiques à cette région en raison de sa grande taille et de son exposition à ce risque.

Nous commençons par représenter l’évolution mensuelle du SWI uniforme sur la région Nouvelle-Aquitaine sur les dix dernières années :




FIGURE 2 – Évolution mensuelle moyenne du SWI en Nouvelle-Aquitaine (10 dernières années)

Ce graphique permet de mettre en évidence la forte saisonnalité du SWI, qui suit des cycles annuels marqués par des épisodes de sécheresse et des périodes plus humides. La combinaison de cette analyse temporelle et de la cartographie du niveau d’argile permet de comprendre le risque RGA et les mécanismes qui l’accentuent.

Enfin, pour illustrer la variabilité spatiale et saisonnière de l’humidité des sols, des [cartes du SWI uniforme](#) ont été produites pour la Nouvelle-Aquitaine à deux périodes contrastées de l’année 2024 : janvier (hiver) et août (été). Ces cartes mettent en évidence la forte variabilité du SWI uniforme en Nouvelle-Aquitaine en fonction des périodes de l’année.

3 Modélisation du SWI uniforme

3.1 Modèles classiques de régression

Pour modéliser le SWI uniforme à l’échelle de la France, nous utilisons dans un premier temps des modèles de régression classiques : régression linéaire Ridge, Random Forest et XGBoost. Leurs métriques de performance sont renseignées dans le tableau suivant :

Algorithme	R^2	RMSE
Régression Ridge	0,795	0,1544
Random Forest	0,789	0,1566
XGBoost	0,860	0,1275

TABLE 1 – Comparaison des performances des modèles de régression classiques (R^2 et RMSE)

Les métriques d’évaluation des algorithmes de régression classiques désignent le modèle XGBoost comme étant le plus performant, avec un R^2 de 0,860 et une RMSE de 0,1275. Cependant, ces résultats peuvent être améliorés puisque les modèles de régression étudiés dans cette partie traitent les observations du jeu de données de façon indépendante.

En effet, le SWI uniforme est un processus continu : la valeur de l’indicateur à une date t dépend des conditions climatiques à cette date, mais également des observations passées des variables explicatives et du SWI uniforme. Pour le modéliser de façon optimale, il est donc nécessaire de passer d’une régression instantanée à une modélisation intégrant l’historique de la série temporelle.

3.2 Modèles à dimension temporelle

Pour intégrer l'historique de la série temporelle à nos modèles de prédiction, nous enrichissons la base en incluant trois types de variables :

- Des variables retardées (*lag*) : SWI uniforme (à dates $t - 1$ et $t - 2$), réserves de neige ;
- Des variables de cumul à 3 mois : précipitations liquides, solides et pluies efficaces ;
- Des variables de différence de réserves de neige permettant de capter l'apport hydrique lié à la fonte des neiges.

L'ajout de ces variables temporelles à des modèles de régression classiques permet ainsi d'enrichir les algorithmes de modélisation en ajoutant des informations extraites des observations précédentes. Pour éviter des phénomènes de fuite d'informations causés par la présence de variables dépendant des observations antérieures, la base de test est constituée de l'ensemble des observations réalisées à partir de 2018. De plus, la prévision de la variable SWI uniforme est réalisée de façon récursive. La valeur du SWI uniforme est prédite pour chaque date, puis ces prévisions sont réinjectées dans la modélisation des dates ultérieures.

Nous utilisons deux modèles de régression pour notre modélisation avec composantes temporelles : régression linéaire Ridge et XGBoost. Les résultats de ces modèles sont affichés ci-dessous :

Algorithme	R ²	RMSE
Régression Ridge	0,900	0,1079
XGBoost	0,977	0,0522

TABLE 2 – Comparaison des performances des modèles temporels de régression (R² et RMSE)

Nous observons une augmentation considérable de la performance des modèles sans ajout réel de complexité aux modèles. En particulier, le modèle XGBoost atteint un R² de 0,977, ce qui correspond à une part de variance inexpliquée 6 fois plus petite que sans composante temporelle. De plus, un modèle naïf qui prédit simplement l'observation au temps t comme étant égale à l'observation au temps $t - 1$ obtient un R² de 0,665. La différence significative de R² entre les algorithmes testés et le modèle naïf montre leur apport dans la modélisation.

Pour illustrer la précision de la modélisation avec XGBoost, nous représentons ci-dessous l'évolution des valeurs réelles de SWI uniforme et des valeurs prédites par le modèle pour deux points aléatoires :




FIGURE 3 – Évolution des valeurs réelles et prédites par le modèle de XGBoost temporel

L'analyse de [l'histogramme d'importance des variables](#) issu du modèle XGBoost enrichit les constats préliminaires de la matrice de corrélation. Celle-ci confirme l'impact des variables

météorologiques (précipitations, ensoleillement, température maximale), mais elle permet surtout d'illustrer la plus-value apportée par la composante temporelle, avec plusieurs variables de retard et de cumul possédant une forte importance.

Enfin, nous avons réalisé une modélisation avec un modèle XGBoost temporel spécifique à la région Nouvelle-Aquitaine pour évaluer la pertinence de l'utilisation d'algorithmes spécifiques aux régions. La performance de ce modèle est légèrement inférieure à celle du modèle entraîné sur l'ensemble de la France, ce qui indique qu'il est plus pertinent d'entraîner les modèles sur l'ensemble du territoire afin d'observer une grande variété de situations.

4 Prédiction des événements de sécheresse

4.1 Création de la variable indicatrice de sécheresse

Dans le cadre du dispositif CatNat, une sécheresse est définie comme anormale si sa période de retour est supérieure ou égale à 25 ans. Pour identifier les zones concernées, Météo France applique une méthodologie normalisée.

Météo France établit d'abord un indicateur mensuel de l'humidité des sols en calculant la moyenne du SWI uniforme sur les trois derniers mois. Ensuite, pour chaque point de la grille et pour chaque mois, le seuil correspondant à une période de retour de 25 ans est donné par la deuxième observation la plus basse sur une période glissante de 50 ans. Les observations situées en-dessous de ce seuil sont alors considérées comme des événements de sécheresse anormale. Cette caractérisation des événements extrêmes sert de base technique à l'identification des communes sinistrées dans le cadre du dispositif CatNat.

Dans le cadre de notre modélisation, nous créons une indicatrice des événements de sécheresse anormale en reproduisant la méthodologie de Météo France. Cependant, nous avons décidé de modifier la méthode de calcul des quantiles pour les remplacer par des quantiles calculés sur l'ensemble des années observées. Cela nous permet de disposer d'observations de la variable sécheresse pour l'ensemble des données.

4.2 Prédiction de la variable indicatrice

Pour prédire la variable indicatrice des événements de sécheresse, nous utilisons les prédictions de SWI uniforme réalisées précédemment auxquelles nous appliquons la règle métier de détermination des événements de sécheresse. Ce choix se justifie par trois arguments :

- Le modèle XGBoost à composantes temporelles a de très bonnes performances (0,977 de R^2) garantissant la fiabilité de la variable sous-jacente ;
- La variable de sécheresse est le fruit d'un calcul administratif dont la formule est connue, cette approche de modélisation reprend ce processus à deux étapes et peut être adaptée en cas de changement de méthode de caractérisation des sécheresses ;
- La robustesse d'un modèle de classification peut être affectée par le déséquilibre des classes.

En appliquant cette méthode, nous obtenons la [première matrice de confusion](#) présentée en annexe. Nous avons retenu le F2-score comme métrique d'évaluation afin de privilégier le rappel, considérant qu'un faux négatif, correspondant à un sinistre manqué, est ici plus préjudiciable qu'un faux positif.

Afin d'optimiser la performance du modèle et de maximiser le F2-score, nous avons introduit une marge de sécurité en appliquant un coefficient multiplicateur au seuil réglementaire. Ce procédé permet de compenser le phénomène de lissage des extrêmes inhérent aux algorithmes classiques de régression. Une comparaison des performances de modèles ajustés a permis d'identifier un coefficient optimal de 1,06. Les performances des modèles de classification "classique" et "prudent" (ajusté) sont détaillées ci-dessous :

Algorithme	Précision	Rappel	F2-Score
Modèle classique	0,798	0,693	0,712
Modèle prudent	0,609	0,837	0,779

TABLE 3 – Comparaison des performances des modèles de prédiction de la sécheresse

Nous avons également testé la précision du modèle prudent en l'appliquant à un cas concret. En 2022, la région Nouvelle-Aquitaine a connu un été particulièrement chaud et sec marqué par des feux de forêt touchant le département de la Gironde. Nous représentons ci-dessous deux cartes des sécheresses anormales dans la région en 2022 afin de comparer les observations réelles et les prédictions réalisées par le modèle prudent :




FIGURE 4 – Carte de la sécheresse réelle et prédite en été 2022 en Nouvelle-Aquitaine

Nous pouvons observer que les cartes sont très similaires, ce qui indique une modélisation précise et efficace des phénomènes de sécheresse extrême par le modèle ajusté.

Conclusion

L'objectif de ce projet était d'étudier l'apport des méthodes de Machine Learning supervisé pour la modélisation de l'humidité des sols et la détection des événements de sécheresse anormale dans le cadre du dispositif CatNat.

Sur le plan de la modélisation physique du SWI uniforme, les résultats obtenus soulignent l'importance de l'intégration de la dimension temporelle dans la modélisation. En particulier, l'algorithme de XGBoost temporel, qui atteint un R^2 de 0,977, permet de reproduire fidèlement la dynamique du SWI uniforme à l'aide de méthodes moins coûteuses et de données publiques.

Sur le plan de la détection des sécheresses, les résultats robustes du modèle de régression par XGBoost temporel nous ont permis d'explorer une approche de seuillage d'une variable continue plutôt qu'une classification binaire directe. La méthode de détection des sécheresses utilisant une estimation de l'indice sous-jacent a apporté des résultats concluants, avec un F2-score atteignant 0,779 après un ajustement du seuil. Cette approche offre également une grande adaptabilité puisqu'elle peut être ajustée en cas de changement de méthodologie d'identification des zones de sécheresse.

Ainsi, les méthodes de Machine Learning constituent une alternative simple et efficace au modèle SIM traditionnel utilisé par Météo France. Cependant, les méthodes employées dans ce projet peuvent être enrichies en intégrant la modélisation des dépendances spatiales entre les points ou en projetant les modèles sur des scénarios climatiques futurs.

5 Bibliographie

Modélisation d'un cas de sécheresse extrême réalisée par la CCR

Méthode de caractérisation des événements de sécheresse anormale par Météo France

Définition de l'indicateur SWI Uniforme par Météo France

Définition des indicateurs SWI et SWI Uniforme par Météo France

6 Annexe

A Matrice de corrélation




FIGURE 5 – Matrice de Correlation

B Description des variables météorologiques et hydrologiques

Nom du champ	Descriptif	Unité	Précision
DATE	Date de la mesure	AAAA-MM-JJ	–
PRENEI	Précipitations solides, cumul quotidien]06UTC–06UTC]	mm	0,1
PRELIQ	Précipitations liquides, cumul quotidien]06UTC–06UTC]	mm	0,1
T	Température moyenne quotidienne]00UTC–00UTC]	°C	0,1
FF	Vent moyen quotidien]00UTC–00UTC]	m/s	0,1
Q	Humidité spécifique moyenne quotidienne]00UTC–00UTC]	g/kg	–
HU	Humidité relative moyenne quotidienne]00UTC–00UTC]	%	–
DLI	Rayonnement atmosphérique, cumul quotidien]00UTC–00UTC]	J/cm ²	–
SSI	Rayonnement visible, cumul quotidien]00UTC–00UTC]	J/cm ²	–
EVAP	Évapotranspiration réelle totale, cumul quotidien]06UTC–06UTC]	mm	0,1
ETP	Évapotranspiration potentielle (Penman–Monteith)	mm	0,1
PE	Pluies efficaces, cumul quotidien]06UTC–06UTC]	mm	0,1
SWI	Indice d’humidité des sols, moyenne quotidienne]06UTC–06UTC]	%	–
SSWI_10J	Indice de sécheresse de l’humidité des sols intégré sur 10 jours	–	–
DRAINC	Drainage, cumul quotidien]06UTC–06UTC]	mm	0,1
RUNC	Ruissellement, cumul quotidien]06UTC–06UTC]	mm	0,1
RESR_NEIGE	Équivalent en eau du manteau neigeux, moyenne quotidienne	mm	0,1
RESR_NEIGE6	Équivalent en eau du manteau neigeux à 06 UTC	mm	0,1
HTEURNEIGE	Épaisseur moyenne quotidienne du manteau neigeux	m	–
HTEURNEIGE6	Épaisseur du manteau neigeux à 06 UTC	m	–
HTEURNEIGEX	Épaisseur maximale horaire du manteau neigeux	m	–
SNOW_FRAC	Fraction de maille recouverte par la neige	%	–
ECOULEMENT	Écoulement à la base du manteau neigeux	mm	0,1
WG_RACINE	Contenu en eau liquide dans la couche racinaire à 06 UTC	m ³ /m ³	–
WGI_RACINE	Contenu en eau gelée dans la couche racinaire à 06 UTC	m ³ /m ³	–
TINF_H	Température minimale journalière (min horaire)]18UTC–18UTC]	°C	0,1
TSUP_H	Température maximale journalière (max horaire)]06UTC–06UTC]	°C	0,1
LAMBX	Coordonnée X en Lambert II étendu	hm	–
LAMBY	Coordonnée Y en Lambert II étendu	hm	–

TABLE 4 – Description des variables issues de la base SAFRAN–SIM et du SWI utilisées dans l’analyse

C Cartes spatiales du SWI – Région Nouvelle-Aquitaine




FIGURE 6 – Distribution spatiale de l'indice d'humidité des sols (SWI) en région Nouvelle-Aquitaine pour le mois de janvier 2024.




FIGURE 7 – Distribution spatiale de l'indice d'humidité des sols (SWI) en région Nouvelle-Aquitaine pour le mois d'août 2024.

D Histogramme d'importance des variables dans le modèle XG-Boost temporel




FIGURE 8 – Histogramme de l'importance des variables explicatives pour le modèle XGBoost temporel

E Matrices de confusion




FIGURE 9 – Matrice de confusion pour le modèle de prédiction de la sécheresse




FIGURE 10 – Matrice de confusion pour le modèle prudent de prédiction de la sécheresse